

FINAL PROJECT

ENGINEERING DATA ANALYSIS - ISYE6158011

D6688 - Amir Tjolleng S.Si., M.Sc., Ph.D.

LINK DATASET

Materi	Link Dataset	Nama Dataset
Descriptive Analytic	https://www.kaggle.com/datasets/kundanbedmutha/exam-score-prediction-dataset	Exam Score Prediction Dataset
Descriptive Analytic (T-Test & ANOVA)		
Predictive Analytic		
Data Mining Unsupervised (Cluster Analysis)		
Data Mining Unsupervised (Association Rule)		

EXAM SCORE PREDICTION DATASET

student_id	age	gender	course	study_hours	class_attendance	internet_access	sleep_hours	sleep_quality	study_method	facility_rating	exam_difficulty	exam_score
1	17	male	diploma	2.78	92.9	yes	7.4	poor	coaching	low	hard	58.9
2	23	other	bca	3.37	64.8	yes	4.6	average	online videos	medium	moderate	54.8
3	22	male	b.sc	7.88	76.8	yes	8.5	poor	coaching	high	moderate	90.3
4	20	other	diploma	0.67	48.4	yes	5.8	average	online videos	low	moderate	29.7
5	20	female	diploma	0.89	71.6	yes	9.8	poor	coaching	low	moderate	43.7
6	23	male	b.tech	3.46	65.4	yes	4.2	good	mixed	low	moderate	58.2
7	17	female	b.tech	1.35	80	yes	7.4	average	online videos	high	hard	53.7
8	22	male	b.sc	5.48	51.1	yes	8.2	poor	self-study	low	moderate	47.3
9	18	other	bca	2.89	92	yes	6.6	poor	self-study	low	easy	44.9
10	17	male	bba	6.77	44.8	yes	9.8	average	group study	high	moderate	77.7
11	21	female	ba	5.99	86.9	yes	5.8	average	self-study	medium	easy	63.2
12	24	male	b.com	3.77	96.6	no	4.1	poor	online videos	medium	easy	53.5
13	22	female	ba	6.76	46.4	yes	8.1	good	self-study	medium	hard	63.9
14	23	female	bba	0.81	66	yes	7.1	poor	online videos	medium	moderate	34.1
15	22	male	b.tech	4.65	75.1	yes	7.7	good	group study	high	moderate	83.5
16	23	other	bba	4.84	99.4	yes	7.3	average	coaching	high	moderate	98.5
17	21	male	b.sc	1.97	91.9	yes	8.3	average	self-study	medium	moderate	70.3
18	18	male	bca	0.4	64.9	yes	6.8	poor	self-study	medium	moderate	32.3
19	23	female	b.sc	4.26	98.1	yes	4.4	average	mixed	low	moderate	56.2
20	20	male	b.tech	4.11	59.9	yes	4.3	poor	coaching	high	moderate	49.3

Dataset ini merangkum berbagai faktor penentu keberhasilan akademik mahasiswa melalui kombinasi variabel nominal (seperti gender, course, dan study method), variabel ordinal yang memiliki tingkatan kualitas (seperti sleep quality, facility rating, dan exam_difficulty), serta variabel rasio berupa data numerik presisi (seperti age, study_hours, class_attendance, dan exam_score). Secara kolektif, dataset ini dirancang untuk memberikan gambaran komprehensif mengenai bagaimana interaksi antara karakteristik demografis, kebiasaan belajar, dan kondisi lingkungan dapat digunakan untuk memprediksi serta mengoptimalkan sistem pendidikan.

GENDER (NOMINAL)

COURSE (NOMINAL)

STUDY_METHOD (NOMINAL)

INTERNET ACCESS (NOMINAL)

STUDY_HOURS (RASIO)

EXAM_SCORE (RASIO)

AGE (RASIO)

SLEEP_HOURS (RASIO)

CLASS ATTENDANCE (RASIO)

EXAM_DIFFICULTY (ORDINAL)

SLEEP_QUALITY (ORDINAL)

FACILITY_RATING (ORDINAL)

DATA ANALYTICS UNTUK BISNIS



Timmerman Industries

■

Data analytics dapat membantu mendukung keputusan bisnis di sektor pendidikan dengan cara mengolah data untuk menemukan pola tersembunyi antara kebiasaan harian dan hasil ujian. Analisis terhadap variabel-variabel seperti jam belajar, tingkat kehadiran, dan metode studi dapat memberikan gambaran akurat mengenai faktor apa saja yang paling berkontribusi terhadap nilai tinggi. Informasi ini memungkinkan institusi untuk melakukan segmentasi mahasiswa secara proaktif, sehingga intervensi atau bantuan akademik dapat diberikan tepat sasaran kepada mereka yang berisiko meraih nilai rendah

Selain itu, hasil data analytics digunakan sebagai dasar pengambilan keputusan strategis jangka panjang. Institusi dapat memanfaatkan temuan analisis untuk mengoptimalkan alokasi sumber daya, seperti perbaikan fasilitas yang dinilai rendah oleh mahasiswa atau penyesuaian kurikulum pada mata kuliah dengan tingkat kesulitan tinggi. Dengan demikian, data analytics membantu institusi meningkatkan efisiensi operasional, meminimalkan angka kegagalan akademik, dan menciptakan keunggulan kompetitif melalui keputusan bisnis yang lebih tepat, objektif, dan berbasis data.



DESCRIPTIVE ANALYTIC STATISTICAL MEASURES AND GRAPH



STATISTICAL MEASURE USING EXCEL

EXAM SCORE

CLASS
ATTENDANCE

SLEEP HOURS

STUDY HOURS

Exam Score	
Mean	62.513225
Standard Error	0.133703223
Median	62.6
Mode	100
Standard Deviation	18.90849117
Sample Variance	357.5310382
Kurtosis	-0.618423026
Skewness	-0.049058622
Range	80.401
Minimum	19.599
Maximum	100
Sum	1250264.5
Count	20000

Class Attendance	
Mean	70.017365
Standard Error	0.122204048
Median	69.9
Mode	40.6
Standard Deviation	17.28226214
Sample Variance	298.6765848
Kurtosis	-1.1987279
Skewness	-0.00129028
Range	58.8
Minimum	40.6
Maximum	99.4
Sum	1400347.3
Count	20000

Sleep Hours	
Mean	7.00856
Standard Error	0.012247724
Median	7
Mode	4.1
Standard Deviation	1.732089701
Sample Variance	3.000134733
Kurtosis	-1.20853088
Skewness	-0.0007712
Range	5.8
Minimum	4.1
Maximum	9.9
Sum	140171.2
Count	20000

Study Hours	
Mean	4.0076035
Standard Error	0.016322237
Median	4.04
Mode	7.91
Standard Deviation	2.308312903
Sample Variance	5.328308457
Kurtosis	-1.202388536
Skewness	-0.010298676
Range	7.83
Minimum	0.08
Maximum	7.91
Sum	80152.07
Count	20000


HUBUNGAN ANTAR VARIABEL

EXAM SCORE, CLASS ATTENDANCE, SLEEP HOURS, STUDY HOURS

Variabel `exam_score` dipilih sebagai variabel dependen utama karena merupakan indikator numerik yang menunjukkan performa akademik dan keberhasilan proses pembelajaran mahasiswa. Perolehan skor ini dianalisis bersama variabel `class_attendance` dan `study_hours` untuk melihat sejauh mana keterlibatan aktif mahasiswa di kelas serta intensitas belajar mandiri memengaruhi penguasaan materi. Tingkat kehadiran yang tinggi dan jam belajar yang konsisten diasumsikan memiliki korelasi positif terhadap pencapaian nilai ujian.


Sementara itu, variabel `sleep_hours` dimasukkan dalam analisis untuk menyeimbangkan faktor akademik dengan faktor gaya hidup. Durasi tidur yang cukup merupakan elemen krusial dalam fungsi kognitif dan daya ingat. Dengan menganalisis hubungan antara jam tidur dan skor ujian, kita dapat mengidentifikasi apakah pola istirahat yang buruk menjadi distraksi atau hambatan bagi mahasiswa dalam mencapai hasil maksimal.

GRAFIK EXAM SCORE VS STUDY HOURS




Berdasarkan grafik "Exam Score vs Study Hours", terlihat korelasi positif yang sangat signifikan di mana peningkatan durasi belajar berbanding lurus dengan pencapaian nilai ujian mahasiswa. Mahasiswa pada kelompok intensitas belajar rendah (0-2 jam) memiliki rata-rata skor terendah sebesar 44,69, namun angka ini melonjak secara konsisten hingga mencapai puncaknya pada rata-rata 79,96 bagi mereka yang mengalokasikan waktu belajar antara 6-8 jam. Pola pertumbuhan yang stabil di setiap interval ini membuktikan bahwa kuantitas waktu belajar mandiri merupakan variabel determinan utama dalam performa akademik, sehingga institusi dapat memanfaatkan data ini untuk mengidentifikasi mahasiswa yang membutuhkan dukungan tambahan serta merancang strategi intervensi berbasis bukti guna mengoptimalkan tingkat keberhasilan kelulusan secara menyeluruh.

GRAFIK EXAM SCORE VS CLASS ATTENDANCE



Grafik tersebut menunjukkan adanya korelasi positif yang linier antara tingkat kehadiran di kelas (Class Attendance) dengan pencapaian rata-rata nilai ujian (Exam Score). Data menunjukkan bahwa mahasiswa dengan tingkat kehadiran rendah (interval 40-50%) memiliki rata-rata nilai terendah sebesar 53,79, sementara mahasiswa dengan tingkat kehadiran maksimal (interval 90-100%) berhasil meraih rata-rata nilai tertinggi yaitu 71,07. Tren kenaikan skor yang konsisten ini mengindikasikan bahwa kehadiran di kelas merupakan faktor determinan yang sangat krusial dalam keberhasilan akademik. Dengan adanya grafik tersebut, institusi pendidikan dapat merancang kebijakan strategi intervensi yang lebih personal serta mengoptimalkan sistem monitoring kehadiran guna memastikan setiap mahasiswa mencapai potensi akademik maksimalnya.

GRAFIK EXAM SCORE VS SLEEP HOURS



Grafik tersebut menunjukkan adanya korelasi positif yang konsisten antara Sleep Hours dengan Exam Score. Mahasiswa yang memiliki waktu istirahat sangat terbatas (interval 4-5 jam) menunjukkan performa akademik terendah dengan rata-rata skor 59,14, sementara nilai tersebut terus meningkat secara bertahap hingga mencapai puncak rata-rata 66,30 pada kelompok mahasiswa dengan waktu tidur optimal (interval 9-10 jam). Tren ini membuktikan bahwa kualitas istirahat yang memadai memiliki peran krusial dalam mendukung fungsi kognitif mahasiswa untuk meraih hasil ujian yang lebih baik. Dari perspektif analitik bisnis, informasi ini sangat berharga bagi institusi pendidikan untuk mengambil langkah strategis dalam mempromosikan keseimbangan gaya hidup mahasiswa sebagai upaya preventif guna menekan angka kegagalan akademik dan meningkatkan standar prestasi secara keseluruhan.

STATISTICAL MEASURE USING R-STUDIO

EXAM SCORE

```
exam_score
Min.      : 19.60
1st Qu.: 48.80
Median   : 62.60
Mean     : 62.51
3rd Qu.: 76.30
Max.     :100.00
```

CLASS
ATTENDANCE

```
class_attendance
Min.      :40.60
1st Qu.:55.10
Median   :69.90
Mean     :70.02
3rd Qu.:85.00
Max.     :99.40
```

SLEEP HOURS

```
sleep_hours
Min.      :4.100
1st Qu.:5.500
Median   :7.000
Mean     :7.009
3rd Qu.:8.500
Max.     :9.900
```

STUDY HOURS

```
study_hours
Min.      :0.080
1st Qu.:2.000
Median   :4.040
Mean     :4.008
3rd Qu.:6.000
Max.     :7.910
```

STATISTICAL MEASURE

CODE

```
cat("Minimum exam_score", min(Exam_Score_Prediction$exam_score), "\n")
cat("Maximum exam_score", max(Exam_Score_Prediction$exam_score), "\n")
cat("Mean of exam_score", mean(Exam_Score_Prediction$exam_score), "\n")
cat("Median of exam_score", median(Exam_Score_Prediction$exam_score), "\n")
cat("1st Quartile of exam_score", quantile(Exam_Score_Prediction$exam_score, 0.25), "\n")
cat("3rd Quartile of exam_score", quantile(Exam_Score_Prediction$exam_score, 0.75), "\n")
cat("Interquartile Range of exam_score", IQR(Exam_Score_Prediction$exam_score), "\n")
cat("Standard Deviation of exam_score:", sd(Exam_Score_Prediction$exam_score), "\n")
cat("Variance of exam_score:", var(Exam_Score_Prediction$exam_score), "\n")
cat("Five-number summary of exam_score:\n", fivenum(Exam_Score_Prediction$exam_score), "\n")
```

{EXAM SCORE}

RUN

```
> cat("Minimum exam_score", min(Exam_Score_Prediction$exam_score), "\n")
Minimum exam_score 19.599
> cat("Maximum exam_score", max(Exam_Score_Prediction$exam_score), "\n")
Maximum exam_score 100
> cat("Mean of exam_score", mean(Exam_Score_Prediction$exam_score), "\n")
Mean of exam_score 62.51322
> cat("Median of exam_score", median(Exam_Score_Prediction$exam_score), "\n")
Median of exam_score 62.6
> cat("1st Quartile of exam_score", quantile(Exam_Score_Prediction$exam_score, 0.25), "\n")
1st Quartile of exam_score 48.8
> cat("3rd Quartile of exam_score", quantile(Exam_Score_Prediction$exam_score, 0.75), "\n")
3rd Quartile of exam_score 76.3
> cat("Interquartile Range of exam_score", IQR(Exam_Score_Prediction$exam_score), "\n")
Interquartile Range of exam_score 27.5
> cat("Standard Deviation of exam_score:", sd(Exam_Score_Prediction$exam_score), "\n")
Standard Deviation of exam_score: 18.90849
> cat("Variance of exam_score:", var(Exam_Score_Prediction$exam_score), "\n")
Variance of exam_score: 357.531
> cat("Five-number summary of exam_score:\n", fivenum(Exam_Score_Prediction$exam_score), "\n")
Five-number summary of exam_score:
19.599 48.8 62.6 76.3 100
```

STATISTICAL MEASURE

CODE

```
cat("Minimum sleep_hours", min(Exam_Score_Prediction$sleep_hours), "\n")
cat("Maximum sleep_hours", max(Exam_Score_Prediction$sleep_hours), "\n")
cat("Mean of sleep_hours", mean(Exam_Score_Prediction$sleep_hours), "\n")
cat("Median of sleep_hours", median(Exam_Score_Prediction$sleep_hours), "\n")
cat("1st Quartile of sleep_hours", quantile(Exam_Score_Prediction$sleep_hours, 0.25), "\n")
cat("3rd Quartile of sleep_hours", quantile(Exam_Score_Prediction$sleep_hours, 0.75), "\n")
cat("Interquartile Range of sleep_hours", IQR(Exam_Score_Prediction$sleep_hours), "\n")
cat("Standard Deviation of sleep_hours:", sd(Exam_Score_Prediction$sleep_hours), "\n")
cat("Variance of sleep_hours:", var(Exam_Score_Prediction$sleep_hours), "\n")
cat("Five-number summary of sleep_hours:\n", fivenum(Exam_Score_Prediction$sleep_hours), "\n")
```

{SLEEP HOURS}

RUN

```
> cat("Minimum sleep_hours", min(Exam_Score_Prediction$sleep_hours), "\n")
Minimum sleep_hours 4.1
> cat("Maximum sleep_hours", max(Exam_Score_Prediction$sleep_hours), "\n")
Maximum sleep_hours 9.9
> cat("Mean of sleep_hours", mean(Exam_Score_Prediction$sleep_hours), "\n")
Mean of sleep_hours 7.00856
> cat("Median of sleep_hours", median(Exam_Score_Prediction$sleep_hours), "\n")
Median of sleep_hours 7
> cat("1st Quartile of sleep_hours", quantile(Exam_Score_Prediction$sleep_hours, 0.25), "\n")
1st Quartile of sleep_hours 5.5
> cat("3rd Quartile of sleep_hours", quantile(Exam_Score_Prediction$sleep_hours, 0.75), "\n")
3rd Quartile of sleep_hours 8.5
> cat("Interquartile Range of sleep_hours", IQR(Exam_Score_Prediction$sleep_hours), "\n")
Interquartile Range of sleep_hours 3
> cat("Standard Deviation of sleep_hours:", sd(Exam_Score_Prediction$sleep_hours), "\n")
Standard Deviation of sleep_hours: 1.73209
> cat("Variance of sleep_hours:", var(Exam_Score_Prediction$sleep_hours), "\n")
Variance of sleep_hours: 3.000135
> cat("Five-number summary of sleep_hours:\n", fivenum(Exam_Score_Prediction$sleep_hours), "\n")
Five-number summary of sleep_hours:
4.1 5.5 7 8.5 9.9
```

STATISTICAL MEASURE

CODE

```
cat("Minimum class_attendance", min(Exam_Score_Prediction$class_attendance), "\n")
cat("Maximum class_attendance", max(Exam_Score_Prediction$class_attendance), "\n")
cat("Mean of class_attendance", mean(Exam_Score_Prediction$class_attendance), "\n")
cat("Median of class_attendance", median(Exam_Score_Prediction$class_attendance), "\n")
cat("1st Quartile of class_attendance", quantile(Exam_Score_Prediction$class_attendance, 0.25), "\n")
cat("3rd Quartile of class_attendance", quantile(Exam_Score_Prediction$class_attendance, 0.75), "\n")
cat("Interquartile Range of class_attendance", IQR(Exam_Score_Prediction$class_attendance), "\n")
cat("Standard Deviation of class_attendance:", sd(Exam_Score_Prediction$class_attendance), "\n")
cat("Variance of class_attendance:", var(Exam_Score_Prediction$class_attendance), "\n")
cat("Five-number summary of class_attendance:\n", fivenum(Exam_Score_Prediction$class_attendance), "\n")
```

{CLASS ATTENDANCE}

RUN

```
> cat("Minimum class_attendance", min(Exam_Score_Prediction$class_attendance), "\n")
Minimum class_attendance 40.6
> cat("Maximum class_attendance", max(Exam_Score_Prediction$class_attendance), "\n")
Maximum class_attendance 99.4
> cat("Mean of class_attendance", mean(Exam_Score_Prediction$class_attendance), "\n")
Mean of class_attendance 70.01736
> cat("Median of class_attendance", median(Exam_Score_Prediction$class_attendance), "\n")
Median of class_attendance 69.9
> cat("1st Quartile of class_attendance", quantile(Exam_Score_Prediction$class_attendance, 0.25), "\n")
1st Quartile of class_attendance 55.1
> cat("3rd Quartile of class_attendance", quantile(Exam_Score_Prediction$class_attendance, 0.75), "\n")
3rd Quartile of class_attendance 85
> cat("Interquartile Range of class_attendance", IQR(Exam_Score_Prediction$class_attendance), "\n")
Interquartile Range of class_attendance 29.9
> cat("Standard Deviation of class_attendance:", sd(Exam_Score_Prediction$class_attendance), "\n")
Standard Deviation of class_attendance: 17.28226
> cat("Variance of class_attendance:", var(Exam_Score_Prediction$class_attendance), "\n")
Variance of class_attendance: 298.6766
> cat("Five-number summary of class_attendance:\n", fivenum(Exam_Score_Prediction$class_attendance), "\n")
Five-number summary of class_attendance:
40.6 55.1 69.9 85 99.4
```

STATISTICAL MEASURE

CODE


```
cat("Minimum study_hours", min(Exam_Score_Prediction$study_hours), "\n")
cat("Maximum study_hours", max(Exam_Score_Prediction$study_hours), "\n")
cat("Mean of study_hours", mean(Exam_Score_Prediction$study_hours), "\n")
cat("Median of study_hours", median(Exam_Score_Prediction$study_hours), "\n")
cat("1st Quartile of study_hours", quantile(Exam_Score_Prediction$study_hours, 0.25), "\n")
cat("3rd Quartile of study_hours", quantile(Exam_Score_Prediction$study_hours, 0.75), "\n")
cat("Interquartile Range of study_hours", IQR(Exam_Score_Prediction$study_hours), "\n")
cat("Standard Deviation of study_hours:", sd(Exam_Score_Prediction$study_hours), "\n")
cat("Variance of study_hours:", var(Exam_Score_Prediction$study_hours), "\n")
cat("Five-number summary of study_hours:\n", fivenum(Exam_Score_Prediction$study_hours), "\n")
```

{STUDY HOURS}

RUN


```
> cat("Minimum study_hours", min(Exam_Score_Prediction$study_hours), "\n")
Minimum study_hours 0.08
> cat("Maximum study_hours", max(Exam_Score_Prediction$study_hours), "\n")
Maximum study_hours 7.91
> cat("Mean of study_hours", mean(Exam_Score_Prediction$study_hours), "\n")
Mean of study_hours 4.007604
> cat("Median of study_hours", median(Exam_Score_Prediction$study_hours), "\n")
Median of study_hours 4.04
> cat("1st Quartile of study_hours", quantile(Exam_Score_Prediction$study_hours, 0.25), "\n")
1st quartile of study_hours 2
> cat("3rd Quartile of study_hours", quantile(Exam_Score_Prediction$study_hours, 0.75), "\n")
3rd quartile of study_hours 6
> cat("Interquartile Range of study_hours", IQR(Exam_Score_Prediction$study_hours), "\n")
Interquartile Range of study_hours 4
> cat("Standard Deviation of study_hours:", sd(Exam_Score_Prediction$study_hours), "\n")
Standard Deviation of study_hours: 2.308313
> cat("Variance of study_hours:", var(Exam_Score_Prediction$study_hours), "\n")
Variance of study_hours: 5.328308
> cat("Five-number summary of study_hours:\n", fivenum(Exam_Score_Prediction$study_hours), "\n")
Five-number summary of study_hours:
0.08 2 4.04 6 7.91
```

GRAFIK EXAM SCORE VS SLEEP HOURS




Berdasarkan analisis data yang diproses menggunakan statistik R Studio, grafik ini memvisualisasikan korelasi positif yang signifikan antara durasi istirahat (Sleep Hours) dan performa akademik (Exam Score). Tren garis yang menanjak secara konsisten memperlihatkan bahwa mahasiswa dengan skor ujian rendah cenderung memiliki waktu tidur yang minim (sekitar 6,2 jam), sedangkan mahasiswa dengan pencapaian nilai tertinggi justru memiliki rata-rata waktu istirahat yang paling optimal (mencapai puncaknya di atas 7,6 jam); temuan ini mengonfirmasi hipotesis bahwa kecukupan tidur berperan krusial dalam mendukung fungsi kognitif dan daya ingat yang dibutuhkan untuk meraih hasil ujian yang maksimal.

GRAFIK EXAM SCORE VS STUDY HOURS



Grafik ini merupakan hasil visualisasi data menggunakan R Studio yang menunjukkan korelasi positif yang sangat kuat antara durasi belajar (Study Hours) dengan hasil ujian (Exam Score). Tren grafik bergerak menanjak secara tajam, di mana mahasiswa dengan alokasi waktu belajar yang sangat terbatas (0-1 jam) mencatatkan performa akademik terendah dengan rata-rata skor 41,7. Sebaliknya, nilai ujian terus mengalami peningkatan signifikan seiring bertambahnya durasi belajar, hingga mencapai puncak rata-rata skor 84,1 pada kelompok mahasiswa dengan jam belajar paling intensif (8 jam).

GRAFIK EXAM SCORE VS CLASS ATTENDANCE HOURS






Analisis statistik yang dihasilkan melalui R Studio ini memperlihatkan korelasi linear yang paling kuat dan konsisten dibandingkan variabel lainnya. Grafik menunjukkan pola garis lurus yang menanjak tajam, menandakan bahwa tingkat kehadiran (Class Attendance) adalah prediktor utama kesuksesan ujian. Mahasiswa dengan tingkat partisipasi kelas yang rendah (kisaran 57%) terpuruk pada skor ujian minimal (20). Sebaliknya, setiap kenaikan persentase kehadiran selalu diikuti oleh lonjakan nilai secara proporsional, hingga mencapai puncaknya pada mahasiswa dengan nilai sempurna (100) yang memiliki tingkat kehadiran rata-rata di atas 85%. Data ini menegaskan bahwa kedisiplinan hadir dan interaksi tatap muka di kelas bukan sekadar formalitas administrasi, melainkan faktor determinan terbesar dalam penguasaan materi akademik.

STATISTICAL MEASURE USING GOOGLE COLLAB

	study_hours	class_attendance	sleep_hours	exam_score
count	20000.000000	20000.000000	20000.000000	20000.000000
mean	4.007604	70.017365	7.00856	62.513225
std	2.308313	17.282262	1.73209	18.908491
min	0.080000	40.600000	4.10000	19.599000
25%	2.000000	55.100000	5.50000	48.800000
50%	4.040000	69.900000	7.00000	62.600000
75%	6.000000	85.000000	8.50000	76.300000
max	7.910000	99.400000	9.90000	100.000000

GRAFIK





PREDICTIVE ANALYTIC MULTIPLE LINEAR REGRESSION



Tujuan Multiple Linear Regression

Multiple Linear Regression (MLR) adalah metode statistik yang digunakan untuk menganalisis hubungan antara satu variabel terikat dan dua atau lebih variabel bebas. Dalam penelitian ini, MLR digunakan untuk memprediksi nilai ujian siswa dengan mempertimbangkan beberapa faktor secara simultan, sehingga hasil analisis menjadi lebih representatif dibandingkan penggunaan satu variabel saja.

Variabel yang Digunakan

- Variabel Terikat (Y):
 - Exam Score
- Variabel Bebas (X):
 - Study Hours
 - Class Attendance
 - Sleep Hours

Variabel bebas yang digunakan dipilih karena berkaitan langsung dengan performa akademik siswa. Jam belajar mencerminkan usaha belajar, kehadiran kelas menunjukkan partisipasi dalam pembelajaran, dan jam tidur berhubungan dengan kondisi fisik serta konsentrasi siswa. Kombinasi ketiga variabel ini diharapkan dapat memberikan gambaran yang lebih menyeluruh terhadap faktor-faktor yang memengaruhi nilai ujian.

Data Preparation

```
from google.colab import drive
drive.mount('/content/drive')
cd drive/MyDrive/EDA Class
!pwd
import pandas as pd

Examscoreprediction = pd.read_csv("Exam_Score_Prediction.csv")
Examscoreprediction.shape
Examscoreprediction[Examscoreprediction.isnull().any(axis=1)]

Y = Examscoreprediction.exam_score
Y
X = Examscoreprediction[['study_hours', 'class_attendance', 'sleep_hours']]
X

from sklearn.model_selection import train_test_split
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, random_state=100)
X_train.shape, Y_train.shape
X_test.shape, Y_test.shape
```

Pada tahap ini, dataset dimuat dan diperiksa untuk memastikan tidak terdapat nilai yang hilang sehingga data siap digunakan untuk pemodelan. Selanjutnya, data dibagi menjadi data latih dan data uji dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian. Pembagian ini bertujuan untuk mengevaluasi kinerja model pada data yang belum pernah dilihat sebelumnya, sehingga hasil analisis menjadi lebih objektif dan mengurangi risiko overfitting.

Data Preparation

```
from sklearn import linear_model
from sklearn import metrics
model = linear_model.LinearRegression()
model.fit(X_train, Y_train)
Y_pred = model.predict(X_test)
Y_pred
```

Pada tahap ini, model Multiple Linear Regression dibangun dan dilatih menggunakan data latih. Model mempelajari hubungan antara tiga variabel bebas, yaitu jam belajar, kehadiran kelas, dan jam tidur, terhadap variabel terikat berupa nilai ujian. Setelah proses pelatihan selesai, model digunakan untuk memprediksi nilai ujian pada data uji, sehingga hasil prediksi dapat dibandingkan dengan nilai aktual untuk menilai performa model.

Coefficients Interpretation


Model Multiple Linear Regression digunakan untuk menganalisis pengaruh jam belajar, kehadiran kelas, dan jam tidur terhadap nilai ujian. Koefisien regresi menunjukkan besarnya kontribusi masing-masing variabel independen terhadap nilai ujian, dengan asumsi variabel lain tetap konstan. Berdasarkan hasil model, dapat dilihat faktor mana yang memiliki pengaruh paling dominan.

```
coeff_Examscoreprediction = pd.DataFrame(model.coef_, X.columns, columns=['Coefficient'])  
coeff_Examscoreprediction
```

	Coefficient
study_hours	5.911898
class_attendance	0.340969
sleep_hours	1.442479


Berdasarkan hasil koefisien regresi, jam belajar memiliki pengaruh paling besar terhadap nilai ujian, di mana setiap penambahan satu jam belajar berhubungan dengan peningkatan nilai ujian sekitar 5,9 poin. Kehadiran kelas juga berpengaruh positif terhadap nilai ujian, meskipun pengaruhnya lebih kecil, yaitu sekitar 0,34 poin untuk setiap peningkatan 1% kehadiran. Selain itu, jam tidur memiliki pengaruh positif sedang, di mana setiap tambahan satu jam tidur berhubungan dengan peningkatan nilai ujian sekitar 1,4 poin. Hasil ini menunjukkan bahwa waktu belajar merupakan faktor paling dominan, sementara kehadiran dan istirahat tetap berperan dalam mendukung performa akademik.

Actual vs Predicted Plot Analysis



Grafik Actual vs Predicted Exam Score menunjukkan bahwa model regresi memiliki kemampuan prediksi yang cukup baik, terlihat dari pola titik data yang cenderung mengikuti arah diagonal positif. Hal ini menandakan adanya hubungan linear yang kuat antara nilai aktual dan nilai prediksi, sehingga model mampu menangkap pola utama dalam data. Meskipun demikian, sebaran titik yang masih terlihat di sekitar pola tersebut menunjukkan adanya kesalahan prediksi yang tidak dapat dihindari, yang kemungkinan disebabkan oleh faktor-faktor lain di luar variabel yang digunakan dalam model. Tidak tampak pola penyimpangan yang ekstrem, sehingga dapat disimpulkan bahwa model tidak mengalami bias yang signifikan dan masih layak digunakan untuk analisis dan prediksi nilai ujian.


Histogram of Residuals Analysis



Dari histogram residual, terlihat bahwa distribusi residual membentuk pola mendekati distribusi normal dan terpusat di sekitar nol, yang menunjukkan bahwa sebagian besar prediksi model cukup akurat dan tidak memiliki kecenderungan untuk selalu melebihkan atau meremehkan nilai ujian. Penyebaran residual yang relatif simetris juga menandakan bahwa kesalahan terjadi secara acak, bukan karena pola sistematis tertentu, sehingga model dapat dikatakan stabil dan memenuhi asumsi dasar regresi linear.

Residual dihitung menggunakan rumus $\text{residuals} = Y_{\text{test}} - Y_{\text{pred}}$ untuk mengukur selisih antara nilai ujian aktual dan nilai yang diprediksi oleh model, sehingga kita dapat melihat seberapa besar dan bagaimana pola kesalahan prediksi yang dihasilkan.


Residuals vs Predicted Values Analysis



Pada grafik ini, residual terlihat menyebar di sekitar garis nol tanpa pola melengkung yang jelas, yang menunjukkan bahwa hubungan antara variabel independen dan dependen bersifat linear. Namun, terdapat sedikit perubahan sebaran residual pada beberapa rentang nilai prediksi yang membentuk pola menyerupai kipas, sehingga mengindikasikan heteroskedastisitas ringan. Meskipun demikian, dengan ukuran sampel yang besar, pelanggaran ini tidak dianggap serius dan tidak secara signifikan memengaruhi keandalan estimasi model.

Grafik Residuals vs Predicted Values digunakan untuk mengevaluasi asumsi homoskedastisitas dan linearitas pada model regresi linear berganda, yaitu apakah residual tersebar secara acak dan memiliki varians yang konstan di seluruh nilai prediksi.

Q-Q Plot of Residuals Analysis



Pada grafik ini, titik-titik residual menunjukkan penyimpangan yang cukup jelas dari garis diagonal, baik pada bagian tengah maupun ekor distribusi, yang menandakan bahwa residual tidak berdistribusi normal. Hasil ini konsisten dengan uji normalitas formal dan umum terjadi pada dataset dengan jumlah observasi yang besar. Meskipun asumsi normalitas tidak sepenuhnya terpenuhi, hal ini tidak menjadi masalah yang signifikan karena, berdasarkan Teorema Limit Pusat, estimasi koefisien dan inferensi statistik tetap valid pada ukuran sampel yang besar.

Grafik Q-Q Plot of Residuals digunakan untuk menguji asumsi normalitas residual dengan membandingkan kuantil residual aktual terhadap kuantil teoritis dari distribusi normal.

Model Evaluation

```
import numpy as np
def evaluate(true, predicted):
    mae = metrics.mean_absolute_error(true, predicted)
    mse = metrics.mean_squared_error(true, predicted)
    rmse = np.sqrt(metrics.mean_squared_error(true, predicted))
    r2_square = metrics.r2_score(true, predicted)
    return mae, mse, rmse, r2_square
Y_pred = model.predict(X_test)
train_pred = model.predict(X_train)
print_evaluate(Y_test, Y_pred)
print_evaluate(Y_train, train_pred)
```

```
MAE: 9.200571454821615
MSE: 131.56563031685872
RMSE: 11.470206202020028
R2 Square 0.6266399977531993
```

```
MAE: 9.278203908434673
MSE: 132.75247211316946
RMSE: 11.521825901877248
R2 Square 0.6299709814460357
```

Hasil evaluasi menunjukkan bahwa model regresi linear memiliki kinerja yang cukup baik. Nilai R^2 sebesar 0.63 pada data uji mengindikasikan bahwa model mampu menjelaskan sekitar 63% variasi nilai ujian, sementara sisanya dipengaruhi oleh faktor lain di luar model. Nilai MAE sebesar 9.20 dan RMSE sebesar 11.47 menunjukkan bahwa rata-rata kesalahan prediksi berada pada kisaran 9–11 poin, yang masih dapat diterima dalam konteks penilaian akademik. Selain itu, performa model pada data latih dan data uji relatif konsisten (R^2 train $\approx R^2$ test), sehingga tidak ditemukan indikasi overfitting. Hal ini menunjukkan bahwa model memiliki kemampuan generalisasi yang baik dan dapat digunakan untuk analisis lebih lanjut.

Conclusion

Berdasarkan hasil Multiple Linear Regression, model yang dibangun mampu menjelaskan sekitar 63% variasi nilai ujian, dengan performa yang konsisten antara data latih dan data uji. Seluruh variabel independen, yaitu jam belajar, kehadiran kelas, dan jam tidur, memiliki pengaruh positif dan signifikan secara statistik terhadap nilai ujian. Selain itu, hasil evaluasi menunjukkan bahwa model memiliki tingkat kesalahan prediksi yang relatif stabil, sehingga regresi linear berganda dapat digunakan untuk memahami hubungan antara variabel akademik dan nilai ujian.

Recommendation

Berdasarkan hasil Multiple Linear Regression, jam belajar merupakan faktor yang paling berpengaruh terhadap nilai ujian, diikuti oleh kehadiran kelas dan jam tidur, yang seluruhnya berpengaruh positif dan signifikan. Oleh karena itu, disarankan agar siswa meningkatkan konsistensi jam belajar sebagai prioritas utama, serta menjaga tingkat kehadiran kelas dan pola tidur yang cukup untuk mendukung performa akademik. Selain itu, penelitian atau pengembangan selanjutnya disarankan untuk menambahkan variabel lain yang relevan serta mempertimbangkan pendekatan model alternatif guna meningkatkan akurasi prediksi.



DESCRIPTIVE ANALYTIC T-TEST AND ANOVA USING GOOGLE COLAB



T-TEST

INTERPRETASI

Dalam dataset *exam score prediction* ini, totalnya ada 13 variabel. Dengan variabel yang dapat berpengaruh terhadap nilai ujian berjumlah 9 (*excluding student id, age, gender, and exam score*).

```
t_test_results = perform_all_t_tests(Exam_Score_Prediction, categorical_vars)
print("Hasil T-test untuk semua variabel kategorikal (2 variabel):")
print(t_test_results.to_string())

# Retrieve the p-value from the t_test_results DataFrame
# Assuming 'internet_access' is the relevant variable and is present in the results.
if not t_test_results.empty and 'p-value' in t_test_results.columns:
    # Get the p-value for the 'internet_access' variable
    p_value_internet_access = t_test_results.loc[t_test_results['Variable'] == 'internet_access', 'p-value'].iloc[0]

    if p_value_internet_access < 0.05:
        print("Terdapat perbedaan signifikan antara dua kelompok internet access")
    if p_value_internet_access > 0.05:
        print("Tidak ada perbedaan signifikan antara dua kelompok internet access")
else:
    print("Tidak dapat mengekstrak p-value karena t_test_results kosong atau tidak memiliki kolom 'p-value' untuk 'i
```

Hasil T-test untuk semua variabel kategorikal (2 variabel):

	Variable	Category1	Mean1	N1	Category2	Mean2	N2	t-statistic	p-value	Significant
0	internet_access	yes	62.450914	16988	no	62.864663	3012	-1.093044	0.274438	False

Tidak ada perbedaan signifikan antara dua kelompok internet access

Pada google colab, kami melakukan T-test terhadap dua kelompok "internet access" dan hubungannya dengan "exam score". Hasil dari perhitungan google colab menyatakan bahwa dengan p value 0,274438 => 0,05 , tidak ada perbedaan signifikan di antara dua kelompok "internet access". Artinya murid yang memiliki akses internet nilai ujiannya tidak jauh berbeda dari murid yang tidak memiliki akses internet. Keberadaan akses internet tidak berpengaruh signifikan terhadap nilai ujian murid.

ANOVA

INTERPRETASI

ANOVA test kami lakukan terhadap variabel "sleep quality", dimana variabel ini terbagi dalam 3 kategori yaitu "good", "average", dan "poor".

```
from scipy.stats import f_oneway

poor_scores = Exam_Score_Prediction[Exam_Score_Prediction['sleep_quality'] == 'poor']['exam_score']
average_scores = Exam_Score_Prediction[Exam_Score_Prediction['sleep_quality'] == 'average']['exam_score']
good_scores = Exam_Score_Prediction[Exam_Score_Prediction['sleep_quality'] == 'good']['exam_score']

f_stat, p_value_anova = f_oneway(poor_scores, average_scores, good_scores)

print("ANOVA untuk Sleep Quality:")
print(f"F-statistic: {f_stat:.4f}")
print(f"p-value: {p_value_anova:.4f}")

if p_value_anova < 0.05:
    print("Terdapat perbedaan signifikan setidaknya antara dua kelompok sleep quality")

ANOVA untuk Sleep Quality:
F-statistic: 411.7933
p-value: 0.0000
Terdapat perbedaan signifikan setidaknya antara dua kelompok sleep quality
```

Pada google colab, kami melakukan ANOVA test untuk menguji apakah ada hubungan signifikan antara 3 kategori "sleep quality" dengan nilai ujian seorang murid. Hasil nya adalah P value anova $0 \leq 0,05$. Artinya ada perbedaan signifikan nilai ujian di antara murid dengan sleep quality yang berbeda. Ini mengindikasikan bahwa kualitas tidur murid saat sebelum ujian akan berpengaruh signifikan terhadap nilai ujian murid. Semakin bagus kualitas tidurnya, semakin tinggi juga nilai murid tersebut.



METODE DATA MINING (UNSUPERVISED)



ASSOCIATION RULES

```
from google.colab import drive
drive.mount('/content/drive')
!pip install apyori

import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from apyori import apriori
```

Sebelum analisis dimulai, kita perlu "memanggil" alat bantu. Python secara bawaan tidak memiliki fungsi Association Rule Mining, jadi kita menginstal pustaka tambahan bernama apyori. Kita juga memanggil pandas yang berfungsi seperti Excel-nya Python untuk mengelola tabel data.



ASSOCIATION RULES

INTERPRETASI

```
# 3. DATA PREPROCESSING (Binning continuous numbers into categories)
# Apriori requires discrete items, so we group scores and hours.
df = exam_data.drop(columns=['student_id']) # Removing ID as it's not a pattern

df['age'] = pd.cut(df['age'], bins=[16, 20, 25], labels=['Age:17-20', 'Age:21-24'])
df['study_hours'] = pd.cut(df['study_hours'], bins=[0, 3, 6, 10], labels=['Study:Low', 'Study:Med', 'Study:High'])
df['class_attendance'] = pd.cut(df['class_attendance'], bins=[0, 60, 85, 101], labels=['Att:Low', 'Att:Med', 'Att:High'])
df['sleep_hours'] = pd.cut(df['sleep_hours'], bins=[0, 6, 8, 12], labels=['Sleep:Low', 'Sleep:Med', 'Sleep:High'])
df['exam_score'] = pd.cut(df['exam_score'], bins=[0, 45, 75, 101], labels=['Score:Low', 'Score:Pass', 'Score:High'])
```

Algoritma Apriori bekerja dengan prinsip "keranjang belanja" (kategorikal), bukan angka pasti. Komputer tidak bisa mencari pola dari angka "7.5 jam" vs "7.6 jam". Oleh karena itu, kita melakukan Binning: mengelompokkan data angka menjadi kategori perilaku.

- Siswa yang belajar 0-3 jam kita labeli "Malas" (Low).
- Siswa yang belajar 6-9 jam kita labeli "Rajin" (High).

Tujuan: Mengubah data angka yang rumit menjadi label perilaku yang mudah dipola.



ASSOCIATION RULES

INTERPRETASI

```
records = df.map(str).values.tolist()

print(f"Converted {len(records)} transactions into list format.")
```

Algoritma Apriori di pustaka ini menuntut format data khusus. Ia tidak bisa membaca tabel baris-kolom biasa. Kode ini mengubah tabel data siswa menjadi sekumpulan "daftar belanja". Setiap baris data siswa dianggap sebagai satu keranjang yang berisi "barang-barang" seperti: {'Gender:Male', 'Study:High', 'Score:High'}.

```
# 4. APPLYING APRIORI
# Adjust min_support or min_confidence to find more or fewer rules
association_rules_obj = apriori(records, min_support=0.08, min_confidence=0.3, min_lift=3, min_support=0.08)
association_results = list(association_rules_obj)
```

Ini adalah otak dari analisis. Kita memerintahkan komputer untuk memindai 20.000 data siswa dan hanya melaporkan pola yang muncul minimal pada 8% populasi (min_support=0.08). Ini penting agar kita tidak terjebak menganalisis kasus langka (pencilan/outlier) yang kebetulan saja terjadi.



ASSOCIATION RULES

INTERPRETASI

Aturan (Rule)	Support	Confidence	Lift	Interpretasi Singkat
High Study \$\\rightarrow\$ High Score	0.16	59.60%	2.39	Belajar giat meningkatkan peluang sukses 2.4x lipat.
Low Study \$\\rightarrow\$ Low Score	0.16	83.70%	2.25	Malas belajar hampir pasti (83%) menyebabkan nilai rendah.
High Attd. \$\\rightarrow\$ High Score	0.1	41.10%	1.52	Kehadiran penuh adalah faktor pendukung kesuksesan.
Good Sleep \$\\rightarrow\$ High Score	0.11	35.30%	1.3	Kualitas tidur yang baik berkorelasi positif dengan nilai.

- Lift > 1.0: Semua aturan di atas memiliki Lift > 1, yang berarti hubungan antar variabel bersifat Positif & Kuat (bukan kebetulan).
- Confidence Tinggi (83%): Ditemukan pola "Jebakan Kegagalan". Jika mahasiswa masuk kategori Low Study, sistem memiliki keyakinan 83% bahwa mereka akan gagal (Low Score).
- Rule Terbaik: Kombinasi Jam Belajar Tinggi (6-9 Jam) adalah prediktor kesuksesan paling akurat dibandingkan variabel lain.

ASSOCIATION RULES



Timmerman Industries

INTERPRETASI

Setelah kode dijalankan, kita mendapatkan serangkaian aturan (rules). Berikut adalah interpretasi dari angka-angka statistik yang muncul:

- Temuan Utama: Rumus Sukses (The Golden Rule)

Rule: Study:High $\rightarrow$ Score:High

Statistik: Lift = 2.39, Confidence = 59.6%.

Analisis: Ini adalah hubungan terkuat yang ditemukan. Angka Lift 2.39 berarti siswa yang rajin belajar memiliki peluang 2,4 kali lipat lebih besar untuk sukses dibanding rata-rata. Confidence hampir 60% menunjukkan konsistensi tinggi: jika Anda melihat siswa belajar keras, kemungkinan besar (60%) dia akan mendapat nilai tinggi.

- Temuan Kedua: Jebakan Kegagalan (The Failure Trap)

Rule: Study:Low $\rightarrow$ Score:Low

Statistik: Lift = 2.25, Confidence = 83.7%.

Analisis: Ini adalah peringatan keras. Nilai Confidence 83,7% sangatlah tinggi. Artinya, kemalasan (Study:Low) adalah prediktor kegagalan yang jauh lebih akurat daripada kerajinan sebagai prediktor kesuksesan. Jika siswa malas, hampir pasti (83%) nilainya akan rendah.

- Temuan Ketiga: Faktor Eksternal (Fasilitas & Kesehatan)

Rule: Sleep:Good & Attendance:High $\rightarrow$ Score:High

Analisis: Faktor kehadiran penuh (>85%) dan tidur cukup terbukti secara statistik mengangkat performa nilai (Lift > 1.3). Ini membuktikan bahwa kecerdasan saja tidak cukup; stamina fisik (tidur) dan disiplin (hadir) adalah fondasinya.

ASSOCIATION RULES



Timmerman Industries

KESIMPULAN



- Berdasarkan hasil algoritma Apriori, kami menyimpulkan 3 pola utama perilaku mahasiswa:
- Determinan Utama adalah Usaha (Effort): Nilai ujian dalam dataset ini bukanlah hasil acak. Variabel Study Hours memiliki korelasi tertinggi. Mahasiswa yang belajar >6 jam/hari memiliki probabilitas sukses dominan dibandingkan faktor demografi (seperti Gender atau Age).
- Pola Kegagalan Lebih Terprediksi: Sangat mudah memprediksi siapa yang akan mendapat nilai rendah. Aturan Study:Low -> Score:Low memiliki tingkat kepastian (confidence) yang jauh lebih tinggi daripada aturan kesuksesan. Artinya, kemalasan hampir menjamin kegagalan.
- Ekosistem Pendukung (Support System): Mahasiswa berprestasi tidak hanya belajar keras, tetapi juga memiliki gaya hidup sehat (Tidur Baik) dan disiplin (Kehadiran Tinggi). Fasilitas kampus yang baik (High Facility Rating) juga berperan sebagai katalisator nilai yang lebih baik.

REKOMENDASI



- Untuk Mahasiswa: Strategi "6-85"
 1. Study Time: Wajib alokasikan waktu belajar minimal 6 Jam per hari (masuk kategori High Study).
 2. Disiplin: Pertahankan kehadiran di atas 85%. Data menunjukkan kehadiran <60% berkorelasi kuat dengan nilai Low.
 3. Metode: Hindari Self-Study jika tidak disiplin. Beralihlah ke metode Coaching/Group Study yang terbukti lebih efektif di data.
- Untuk Institusi/Kampus:
 1. Early Warning System: Gunakan data absensi dan survei jam belajar di awal semester. Jika mahasiswa terdeteksi belajar <3 jam, segera berikan intervensi (karena risiko gagalnya 83%).
 2. Fasilitas: Terus tingkatkan rating fasilitas, karena data menunjukkan fasilitas 'High' berkorelasi dengan peningkatan performa akademik mahasiswa.

ASSOCIATION RULES



Timmerman Industries

CLUSTER ANALYSIS

Variabel

1. exam score (nilai ujian)
2. study hours (jam belajar)

Kenapa

- faktor utama
- hubungan jelas dan mudah dianalisis,
- efektif digunakan untuk proses clustering




GALLERY

```
# distribution of exam_score
sns.set(style="whitegrid")
sns.displot(df["exam_score"], kde=True, color="darkblue")

plt.title('Distribution of Exam Score', fontsize = 15)
plt.xlabel('Exam Score')
plt.ylabel('Count')

plt.show()
```




Distribution Graph
(Grafik Distribusi)

```
# exam_difficulty Analysis
genders = df["exam_difficulty"].value_counts()

colors = {
    "easy": "green",
    "moderate": "yellow",
    "hard": "red"
}

sns.set(style="whitegrid")
sns.barplot(x=genders.index, y=genders.values, palette=colors,
            hue=genders.index, legend=False, order=["easy", "moderate", "hard"])
plt.title('Exam Difficulty Analysis', fontsize = 15)
plt.xlabel('Exam Difficulty')
plt.ylabel('Frequency')

plt.show()
```




Analysis Graph
(Grafik Analisis)

```
# scatterplot of the above data
sns.scatterplot(x="study_hours", y="exam_score", data=X, s=1, color="dodgerblue")

plt.xlabel('Study Hours')
plt.ylabel('Exam Score')
plt.title('Exam Score vs Study Hours')

plt.show()
```



Scatter Plot
(Diagram Pencar)


GALLERY

```
wcss = []
for i in range(1, 11):
    k_means = KMeans(n_clusters=i, n_init="auto")
    k_means.fit(X)
    wcss.append(k_means.inertia_)

# the elbow curve
plt.plot(range(1, 11), wcss)
plt.plot(range(1, 11), wcss, linewidth=2.5, color="red", marker="8")

plt.title("Elbow Curve")
plt.xlabel("Number of clusters (values of k)")
plt.ylabel("WCSS values")
plt.xticks(np.arange(1, 11, 1))

plt.show()
```




Elbow Curve
(Kurva Siku)

```
colors = ["steelblue", "orange", "green",]

# scatterplot of the clusters
sns.scatterplot(
    x="study_hours",
    y="exam_score",
    hue="label",
    palette=colors,
    legend="full",
    data=df,
    s=10,
    alpha=0.6
)

plt.xlabel('Study Hour')
plt.ylabel('Exam Score')
plt.title('Study Hours vs Exam Score')
plt.show()
```




Scatter Plot of Clusters
(Diagram pencar berdasarkan cluster)

INTERPRETASI & KESIMPULAN

Untuk Cluster Analisis kami akan menggunakan 3 grafik


01

SCATTER PLOT




02

ELBOW CURVE



03

SCATTER PLOT OF CLUSTERS



SCATTER PLOT


EXAM SCORE VS STUDY HOURS

INTEPRETASI

- Scatter plot menunjukkan adanya hubungan positif antara **study hours** dan **exam score**
- Pola sebaran data membentuk tren menaik, yang mengindikasikan **korelasi** yang cukup kuat antara kedua variabel
- Terdapat **variasi** nilai ujian pada jam belajar yang **sama**, yang menunjukkan bahwa **faktor lain** di luar jam belajar turut memengaruhi hasil ujian

KESIMPULAN

- **Jam belajar** merupakan variabel penting yang berkontribusi terhadap pencapaian **nilai ujian**
- Siswa dengan jam belajar yang **lebih tinggi** cenderung memperoleh hasil akademik yang **lebih baik**
- Namun demikian, hasil ujian tidak sepenuhnya ditentukan oleh **jam belajar**
- Scatter plot ini memberikan dasar yang kuat untuk proses analisis clustering, mengelompokkan siswa berdasarkan **pola belajar** dan **performa akademik**



ELBOW CURVE


WCSS VALUES VS NUMBER OF CLUSTERS (VALUES OF K)

INTEPRETASI


- Grafik Elbow Method menunjukkan penurunan nilai **WCSS** seiring bertambahnya jumlah cluster.
- Penurunan paling tajam terjadi dari **1 ke 2 cluster**, menandakan pemisahan data yang signifikan.
- Penurunan masih terlihat **hingga 3 cluster**, namun setelah itu kurva mulai landai.
- Hal ini menunjukkan bahwa **3 cluster** sudah cukup untuk merepresentasikan pola hubungan antara **study hour** dan **exam score**.
- Penambahan cluster di atas tiga tidak memberikan peningkatan yang berarti terhadap kualitas pengelompokan.

KESIMPULAN

- Jumlah **3 cluster** merupakan pilihan paling optimal berdasarkan Elbow Method.
- Tiga cluster mampu mengelompokkan siswa berdasarkan **pola jam belajar** dan **nilai ujian** secara efektif.



SCATTER PLOT OF CLUSTERS



INTEPRETASI

- Scatter plot menunjukkan data siswa terbagi menjadi 3 klaster berdasarkan **jam belajar** dan **nilai ujian**.
- Klaster pertama berisi siswa dengan **jam belajar rendah** dan **nilai rendah**
- Klaster kedua berisi siswa dengan **jam belajar dan nilai sedang**
- Klaster ketiga berisi siswa dengan **jam belajar tinggi dan nilai tinggi**
- Terlihat **hubungan positif**, di mana semakin lama jam belajar, nilai ujian cenderung lebih tinggi.

KESIMPULAN

- Data siswa dapat dikelompokkan dengan baik ke dalam 3 klaster utama.
- **Jam belajar berpengaruh terhadap nilai ujian**, namun bukan satu-satunya faktor.
- Hasil clustering membantu memahami **pola belajar dan performa akademik** siswa secara sederhana dan jelas.



Kelompok Anak Baik-Baik

THANK YOU